Análisis de Sentimientos con Modelos de Lenguaje para Sistemas de Recomendación: Una Revisión Sistemática de la Literatura

Llave Huachaca Yoseth Orlando
Escuela Profesional de Ingeniería de Sistemas, Universidad Peruana Unión
Juliaca, Perú
yoseth.llave@upeu.edu.pe

***Abstract*—Este artículo presenta una Revisión Sistemática de la Literatura (RSL) sobre el análisis de sentimientos en reseñas con modelos de lenguaje para sistemas de recomendación. Adopta la metodologia de Kitchenham y PRISMA, se analizaron 29 estudios recientes para abordar la eficiencia y precisión de los modelos, así como los desafíos en la fusión de características y la baja exactitud. segun la revision de los articulos, estos indican que los modelos híbridos o alternativos a BERT mejoran la precisión, eficiencia e interpretabilidad mediante la combinación de arquitecturas y atención contextual. Los conjuntos de datos empleados son diversos (Yelp, Amazon, Twitter, SemEval) y se justifican por su relevancia y representatividad lingüística. La interpretabilidad se logra con mecanismos de auto-atención y generación de explicaciones en lenguaje natural. Para la eficiencia computacional, se utilizan GRUs, destilación de modelos, fine-tuning y lectura selectiva. Segun la revision resaltan los avances y desafíos del procesamiento del lenguaje natural, proporcionando una comprensión estructurada del campo.**

***Index Terms*—Natural Language Processing, Pretrained Language Models, Video Game Recommendation Systems, Online Review Analysis, Systematic Literature Review.**

I. Introducción

El análisis de sentimientos se ha consolidado como un campo de estudio crucial en la intersección de la minería de texto, la lingüística computacional y el procesamiento del lenguaje natural (PLN), siendo fundamental para comprender las opiniones públicas y apoyar decisiones estratégicas en diversos sectores [1], [2]. El interés de esta investigación se enfoca en la capacidad de los modelos de lenguaje para interpretar comentarios y reseñas de videojuegos en línea, especialmente aquellas publicadas por los usuarios en plataformas digitales como Steam y Epic Games Store. Estas reseñas pueden contener opiniones sobre aspectos específicos del videojuego, como jugabilidad, gráficos, historia, rendimiento, dificultad y experiencia general, por lo que requieren inferencias que van más allá del sentimiento general, como las que permiten el Análisis de Sentimientos Basado en Aspectos (ABSA) y el ABSA Dirigido (TABSA) [3]. Esta investigación se motiva por la necesidad de abordar desafíos como la fusión de características insuficiente y la baja precisión en el análisis de sentimientos dentro del análisis de boca a boca en redes sociales [4], buscando optimizar la eficiencia computacional de los modelos de lenguaje sin comprometer su precisión [5].

La relevancia social de esta investigación es innegable en la era digital. El rápido avance de las tecnologías móviles ha transformado las redes sociales en plataformas esenciales donde las personas expresan sus sentimientos y opiniones, haciendo que la comprensión de estas opiniones sea vital para la toma de decisiones estratégicas, tanto en el ámbito empresarial como político [1]. Las reseñas de usuarios en línea son una referencia clave para las decisiones de compra de los consumidores en el comercio electrónico y, en el ámbito de los videojuegos, permiten conocer la percepción de los jugadores sobre títulos, actualizaciones y experiencias de juego. Plataformas como Steam y Epic Games Store concentran este tipo de contenido generado por usuarios, lo que subraya la importancia de obtener y analizar comentarios auténticos sobre los productos digitales [5]. Sin embargo, la proliferación de comentarios falsos y reseñas fraudulentas amenaza los derechos de los consumidores y el desarrollo saludable del comercio electrónico. Además, el contenido generado por los usuarios en redes sociales influye directamente en las decisiones de compra [4], mientras que el análisis de sentimientos también es crucial para evaluar la percepción pública en contextos políticos y para combatir problemas sociales como los comentarios tóxicos y el discurso de odio, que se ven agravados por la diversidad lingüística en línea [2], [6].

Desde una perspectiva tecnológica, este campo está impulsado por avances significativos en el aprendizaje profundo y el PLN. Modelos como las redes neuronales profundas (DNNs) basadas en CNN, RNN, Transformer y, en particular, BERT, se han convertido en enfoques predominantes en la clasificación de texto, superando consistentemente a los métodos tradicionales [7]. BERT, un Modelo de Lenguaje Grande (LLM) fundamental, utiliza la arquitectura Transformer para generar incrustaciones contextualizadas, lo que ha llevado a un rendimiento de vanguardia en diversas tareas de PLN, incluida la clasificación de texto y la respuesta a preguntas [8]. Sus variantes, como DistilBERT, RoBERTa y ALBERT, buscan mejorar la eficiencia manteniendo la precisión [1]. Innovaciones recientes como la lectura selectiva para textos largos [9], la integración de características estadísticas mediante compuertas adaptativas (Adaptive Gate Network), el aprendizaje contrastivo supervisado (SuperConText) para

mejorar las representaciones textuales [10], y los modelos BERT guiados por contexto (CG-BERT) para un análisis de sentimientos basado en aspectos más eficaz, demuestran la constante evolución tecnológica. Además, el desarrollo de redes de atención de grafos multicapa mejoradas sintáctica y semánticamente (SSEMGAT) y la generación aumentada por recuperación (RAG) marcan la frontera actual [11], [12]. A pesar de estos avances, persisten desafíos, como los altos requisitos computacionales de los modelos BERT complejos y la necesidad de equilibrar la compresión de representaciones de tamaño fijo con la preservación de la información crucial [13], lo que impulsa la innovación tecnológica continua.

La necesidad de una Revisión Sistemática de la Literatura (RSL) en este ámbito es imperativa dada la rápida evolución y la naturaleza fragmentada del conocimiento. La investigación actual en análisis de sentimientos y clasificación de texto a menudo muestra inconsistencias en el preprocesamiento, la aplicación de modelos y la evaluación [6]. Los métodos existentes para la identificación de comentarios falsos se ven limitados por la adquisición de datos y el tamaño de la muestra, lo que les dificulta procesar grandes volúmenes de datos y patrones de comportamiento complejos, y a menudo carecen de un análisis exhaustivo de la interacción entre el contenido del texto y las características del comportamiento del usuario [5]. Aunque se ha explorado la incorporación de conocimiento externo, no siempre se presta suficiente atención a la compatibilidad de esta información adicional, lo que puede introducir ruido en los clasificadores [7]. Además, se han identificado brechas específicas, como la ausencia de investigaciones comparativas sobre el rendimiento de diferentes tipos de modelos de predicción (por ejemplo, aprendizaje automático versus aprendizaje por transferencia) en conjuntos de datos como las reseñas de Yelp [14]. Incluso con modelos tan avanzados como BERT, no está completamente claro cómo las propiedades de sus vectores de tamaño fijo influyen en el equilibrio entre el rendimiento del modelo y la información que codifica como vector de representación de significado [15]. Los desafíos persistentes en la ”extracción de información de correlación más profunda entre la sintaxis y la semántica” y la aplicabilidad general de los marcos existentes a una ”amplia gama de tareas de PLN” hacen que una síntesis estructurada sea esencial [16]. Por lo tanto, una revisión sistemática es fundamental para proporcionar una comprensión coherente de los diversos enfoques, identificar los problemas predominantes y señalar vías prometedoras para futuras investigaciones en el dinámico campo de los modelos de lenguaje para el análisis de sentimientos.

Para guiar esta revisión sistemática de literatura, nos basamos en las siguientes preguntas de investigación:

1) ¿Qué mejoras ofrecen los modelos híbridos o alternativos a BERT en el análisis de sentimientos de reseñas en línea?
2) ¿Qué tipos de conjuntos de datos se han utilizado para entrenar y evaluar modelos de lenguaje en el análisis de sentimientos de reseñas en línea, y cómo se justificó su elección en términos de calidad, relevancia y representatividad del lenguaje natural?
3) ¿Qué mecanismos de interpretabilidad y explicabilidad han sido implementados en modelos de lenguaje para análisis de sentimientos, y cómo permiten entender la lógica detrás de las predicciones generadas?
4) ¿Qué estrategias han sido empleadas para mejorar la eficiencia computacional de los modelos de lenguaje aplicados al análisis de sentimientos sin comprometer significativamente su precisión?

II. Metodología

Esta revisión sistemática de la literatura tiene como finalidad analizar y comparar modelos de lenguaje aplicados al análisis de reseñas en línea, con énfasis en su utilidad para sistemas de recomendación de videojuegos. El contexto de aplicación considera especialmente las reseñas generadas por jugadores en plataformas digitales como Steam y Epic Games Store, donde los comentarios pueden aportar información sobre la experiencia y preferencias de los usuarios. Para ello, se empleó el protocolo propuesto por Kitchenham [17], el cual proporciona una base estructurada y rigurosa para garantizar la trazabilidad, transparencia y calidad metodológica de las revisiones en ingeniería del software y áreas afines.

El protocolo fue adaptado al contexto del procesamiento de lenguaje natural (NLP) y dividido en fases secuenciales. Cada fase responde a un objetivo específico dentro del proceso de revisión, desde la planificación de la búsqueda hasta la extracción sistemática de los datos relevantes.

A. Fase I: Búsqueda y Selección de Estudios

- **Modelo PICOC**
  Se utilizó el enfoque PICOC para delimitar el alcance de la revisión:

TABLE I
Modelo PICOC aplicado a la revisión sistemática

Componente	Descripción
Population	Reseñas en línea generadas por usuarios en plataformas digitales de videojuegos como Steam, Epic Games Store y otras tiendas en línea
Intervention	Aplicación del modelo de lenguaje BERT para análisis semántico y clasificación de comentarios.
Comparison	Comparación con otros enfoques como GPT, RoBERTa, BERTopic, LDA, o métodos clásicos como TF-IDF.
Outcome	Métricas de evaluación como Accuracy, F1-score, Precision, Recall, y escalabilidad de los modelos.
Context	Sistemas de recomendación de videojuegos y comercio electrónico enfocados en productos y contenidos digitales.

- **Palabras Clave y Sinónimos**
  Las palabras clave se definieron y asociaron a los componentes del modelo PICOC. Se consideraron sinónimos relevantes para ampliar el alcance de la búsqueda. Por ejemplo:

TABLE II
PALABRAS CLAVE, SINÓNIMOS Y SU RELACIÓN CON EL MODELO PICO

Keyword	Synonyms	Related to
Review Platforms	Steam, Epic Games Store, Google Reviews, online comments, online review sites, game reviews, videogame reviews	Population
BERT	BERT NLP, BERT language model, Enhanced Representation through Knowledge Integration, language model, pre-trained language model, semantic knowledge extraction, transfer learning	Intervention
PML	ALBERT, BERTopic, GPT, LLMs, RoBERTa, XLNet, classical NLP models	Comparison
Evaluation Metrics	AUC, Accuracy, F1-score, MAE, Model metrics, Performance metrics, RMSE, knowledge extraction accuracy, precision, recall, topic modelling comparison	Outcome

- **Sintaxis de Búsqueda por Base de Datos**
  La búsqueda se llevó a cabo en Scopus, Web of Science, Dimensions y ScienceDirect, utilizando una cadena booleanamente construida a partir de las palabras clave y sus sinónimos asociados al modelo PICOC. La cadena principal utilizada fue:

```
("review platforms" OR "Steam" OR
"Epic Games Store" OR "Google Reviews"
OR "online comments" OR "online
review sites" OR "game reviews" OR
"videogame reviews") AND ("BERT" OR
"BERT NLP" OR "BERT language model" OR
"BERT pre-trained model" OR "ERNIE
transformer" OR "language model"
OR "BERT") AND ("PML" OR "ALBERT"
OR "BERTopic" OR "GPT" OR "LLMs" OR
"RoBERTa" OR "XLNet") AND ("Evaluation
Metrics" OR "AUC" OR "Accuracy" OR
"F1-score" OR "MAE" OR "Model metrics"
OR "Performance metrics" OR "RMSE" OR
"precisi" OR "recall")
```

- **Criterios de Inclusión**
  Se definieron los siguientes criterios para la clasificacion de articulos:

CI01. Artículos publicados entre 2020 y 2025.
CI02. Estudios escritos en idioma inglés.
CI03. Investigaciones que utilicen comentarios o reseñas en línea generadas por usuarios como fuente de datos.
CI04. Trabajos enfocados en el área de ciencias de la computación o ingeniería informática.
CI05. Trabajos que apliquen modelos de lenguaje o técnicas NLP para tareas computacionales específicas.
CI06. Artículos con acceso abierto.
CI07. Artículos que sean empíricos y publicados en revistas de alto impacto.
CI08. Artículos que trabajen con reseñas cualitativas.

- **Criterios de Exclusión**
  Se excluyeron los articulo segun los sigueinte criterios:

CE01. Artículos publicados antes de 2020 o después de 2025.
CE02. Estudios escritos en idiomas distintos al inglés (por ejemplo: chino, español, alemán, etc.).
CE03. Investigaciones que no utilicen comentarios o reseñas en línea como fuente de datos.
CE04. Trabajos fuera del área de ciencias de la computación o ingeniería informática (por ejemplo: estudios en psicología, sociología o análisis de usuarios sin enfoque computacional).
CE05. Estudios que no apliquen modelos de lenguaje ni técnicas NLP para tareas computacionales específicas.
CE06. Artículos que no tengan acceso abierto o cuya descarga completa no esté disponible.
CE07. Trabajos no empíricos o publicados en revistas sin arbitraje o de bajo impacto.
CE08. Artículos que no trabajen con reseñas cualitativas o que usen únicamente datos estructurados, encuestas o entrevistas.

- **Eliminación de Duplicados**
  Tras completar la recolección de artículos desde las distintas bases de datos, los registros fueron gestionados en la plataforma Parsifal. Se procedió con la eliminación automática de duplicados y luego se realizó una revisión manual de títulos, resúmenes e introducciones para descartar aquellos estudios que no cumplían con los criterios definidos. Esta fase redujo significativamente la cantidad de artículos, permitiendo continuar con un conjunto depurado y alineado a los objetivos del estudio.

B. Fase II: Proceso de seleccion de estudios

- **Evaluación de Calidad de los Estudios**
  Los estudios seleccionados fueron sometidos a una evaluación estructurada utilizando una lista de seis preguntas cerradas, diseñadas para verificar la solidez metodológica, la transparencia de los datos y la validez de los resultados reportados. Para ello, se accedió al texto completo de cada artículo y se realizó una revisión minuciosa de todos sus apartados: introducción, metodología, experimentación, resultados y discusión. Esta evaluación profunda permitió identificar estudios con inconsistencias o carencias técnicas importantes. Aquellos artículos que no cumplieron con el umbral mínimo de calidad fueron descartados del análisis.
  A continuación se detallan las preguntas utilizadas y su propósito:

1) **¿El estudio presenta una metodología clara y reproducible?**
   Permite determinar si el artículo describe con precisión los pasos metodológicos y posibilita su replicabilidad.

2) **¿Incluye una discusión crítica de resultados y limitaciones?**
   Evalúa la capacidad del estudio para reconocer sus propias limitaciones, así como para contextualizar los hallazgos.
3) **¿El modelo de lenguaje utilizado está bien descrito técnicamente?**
   Examina si el modelo NLP es explicado con suficiente detalle (arquitectura, configuración, entrenamiento).
4) **¿Se reportan métricas de evaluación como Accuracy, F1-score, Precision, etc.?**
   Verifica la existencia de indicadores cuantitativos que permitan medir el rendimiento del modelo implementado.
5) **¿Los datos de la metodología están disponibles públicamente?**
   Indaga si el dataset o los scripts utilizados están accesibles, promoviendo la reproducibilidad y validación externa.
6) **¿Se realiza comparación con otros modelos o enfoques NLP?**
   Determina si se incluye un análisis comparativo entre técnicas similares o modelos alternativos.

Para garantizar la trazabilidad y transparencia del proceso de selección de artículos, se siguió el esquema PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), ampliamente utilizado en revisiones sistemáticas. Este enfoque permite representar de manera gráfica las distintas fases del filtrado de estudios mediante un diagrama de flujo.

En este trabajo, se aplicaron las cuatro etapas establecidas por PRISMA: (1) *Identificación* de artículos mediante búsquedas en bases de datos académicas; (2) *Cribado*, donde se eliminaron duplicados y se revisaron títulos y resúmenes; (3) *Elegibilidad*, en la cual se analizó el texto completo de los artículos preseleccionados; y (4) *Inclusión*, donde se seleccionaron finalmente los estudios que cumplieron con los criterios de calidad y relevancia establecidos.

A continuación, se presenta un resumen visual del procedimiento mediante un diagrama de flujo que ilustra todo el recorrido seguido para llegar a la muestra final de artículos analizados.

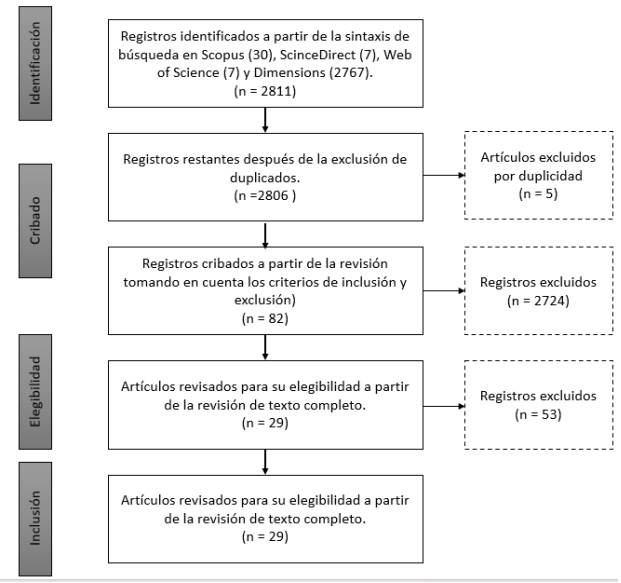


Fig. 1. Diagrama de flujo para la selección de estudios.

La Figura 1 muestra el proceso de selección de estudios siguiendo el enfoque PRISMA, estructurado en cuatro etapas: identificación, cribado, elegibilidad e inclusión. En la fase de identificación se recuperaron un total de 2811 registros a partir de las bases de datos Scopus (30), ScienceDirect (7), Web of Science (7) y Dimensions (2767). Luego de eliminar 5 registros duplicados, se conservaron 2806 artículos únicos. En la etapa de cribado, se descartaron 2724 artículos tras una revisión inicial de títulos y resúmenes, quedando 82 registros. Estos fueron evaluados más detalladamente durante la fase de elegibilidad, accediendo al texto completo de cada uno. Como resultado, se excluyeron 53 estudios por no cumplir con los criterios metodológicos o temáticos definidos. Finalmente, se incluyeron 29 artículos que superaron todas las etapas de selección y que constituyen la muestra final analizada en esta revisión sistemática.

C. Fase III: Extracción y Análisis de Datos

La extracción de datos se realizó mediante una matriz estructurada basada en el enfoque de Kitchenham. Se documentaron las variables clave de cada artículo para facilitar su análisis comparativo.

- **Modelos de Lenguaje Analizados**
  Se identificaron modelos preentrenados como BERT, DistilBERT, XLNet y ERNIE, además de enfoques híbridos como CNN-LSTM, BiLSTM con atención, y MAGRU. También se reportaron modelos clásicos como Logistic Regression y embeddings como GloVe y Word2Vec.
- **Métricas de Evaluación**
  Las métricas más frecuentes fueron Accuracy, F1-score, Precision, Recall y AUC. Algunos estudios lograron F1-score superiores al 90%, y en general se observaron buenos niveles de precisión y rendimiento en las tareas de clasificación.
- **Plataformas y Datos**

Los datasets utilizados incluyeron Yelp, Amazon, IMDb, SemEval, HASOC y Twitter. La mayoría de comentarios fueron en inglés, aunque también hubo casos en hindi, español, alemán y francés. Se analizaron reseñas reales de plataformas abiertas.

- **Beneficios Reportados**
  Los modelos mostraron buena capacidad para analizar texto informal, clasificar contenido ofensivo y manejar tareas multiclase. Se destacó la efectividad de los enfoques híbridos y la escalabilidad de modelos preentrenados.
- **Limitaciones Identificadas**
  Entre las limitaciones se señalaron inconsistencias en los datasets, baja disponibilidad de datos abiertos, y dificultades con frases largas o lenguaje informal multilingüe. Algunos modelos requieren ajustes específicos para obtener buen rendimiento.
- **Técnicas y Herramientas**
  Las arquitecturas incluyeron Transformers, BiLSTM, CNN y modelos secuenciales. Las bibliotecas más utilizadas fueron TensorFlow, Keras, HuggingFace Transformers, FastText y Gensim, además de optimizadores como Adam y funciones como ReLU y Softmax.

III. Resultados

A partir del análisis exhaustivo de los **n**° estudios seleccionados, se detallan a continuación los principales resultados en función de los aspectos clave que responden a las preguntas de investigación planteadas. Los hallazgos se organizan en torno a ...

1) Mejoras que ofrecen los modelos híbridos o alternativos a BERT en el análisis de sentimientos de reseñas en línea : Descripcion de hallazgos mencionado a la Tabla III

Los modelos híbridos o alternativos a BERT ofrecen mejoras significativas en precisión, eficiencia y capacidad de interpretación en el análisis de sentimientos de reseñas en línea [7]. Al combinar BERT con arquitecturas como BiGRU, BiLSTM o capas convolucionales (como en TriCNN-CatBoost), se logra una mejor captura de relaciones secuenciales y una mayor eficiencia computacional [1]. Modelos como X+AGN integran características estadísticas del corpus para resaltar palabras discriminativas, mientras que otros, como CG-BERT o QACG-BERT, adaptan la atención al contexto o al aspecto específico, lo que resulta clave en tareas como ABSA [3]. Además, propuestas como UsbVisdaNet extienden el análisis al ámbito multimodal incorporando información visual y del usuario [18]. Modelos más recientes como SEML, SenDM o LLaMA3 también demuestran mejoras sustanciales al optimizar la transferencia de conocimiento, el aprendizaje semi-supervisado o la eficiencia en tiempo real, superando ampliamente a BERT en distintos conjuntos de datos (IMDb, Yelp, Amazon, SentiHood) [19]. En conjunto, estas alternativas no solo mejoran el rendimiento cuantitativo, sino que también permiten una mayor adaptabilidad a dominios específicos y una interpretación más transparente de las predicciones.

TABLE III
Mejoras de modelos respecto a BERT

Modelo	Mejora respecto a BERT	CITA
BERT+AGN	Aumenta la precisión (hasta +2.86%) al incorporar estadísticas y compuerta adaptativa.	[7]
CG-BERT / QACG-BERT	Superan a BERT en ABSA/TABSA, con mejoras en precisión (e.g., +0.81% en SentiHood).	[3]
RoBERTa híbridos	Mayor precisión (hasta 94.9% en IMDb); aprovechan enmascaramiento dinámico y más datos.	[1]
SSEMGAT	Fusión eficiente de sintaxis-semántica, mejora a BERT en tareas de sentimiento.	[11]
UsbVisdaNet	Precisión superior (+14%) en clasificación multimodal mediante atención al usuario y señales visuales.	[18]
Híbridos de BERT	DistilBERT y RoBERTa mejoran hasta 1.84% en precisión al combinar con BiGRU/BiLSTM.	[20]
PRAG	Supera a Optimus en generación explicable al integrar recuperación personalizada.	[21]
EBERT / AViT+EBERT	Mejora en F1 y precisión con codificación contextual y mecanismos dispersos.	[4]
TriCNN-CatBoost	Precisión alta (0.87–0.89) con extracción convolucional y pérdida de triplete.	[5]
LLaMA3-8B (ajustado)	Supera a XLNet (92.6% vs 91.6%) con mayor velocidad y precisión.	[22]
SEML	Mejora notable en ABSA, aprendiendo de datos etiquetados y no etiquetados.	[19]
AraBERT (base y grande)	Mejor rendimiento en árabe sobre variantes como MARBERT y CAMeL-BERT.	[2]
Modelos fusionados (Fusion-3)	Mejora F1 en detección tóxica (+5.05% MBERT, +0.76% XLM-R).	[23]
SenDM	Supera a BERT y FinBERT incluso en configuraciones de bajo recurso.	[24]
HINT	Mejores resultados en textos largos y mayor interpretabilidad jerárquica.	[16]

2) Tipos de conjuntos de datos que se han utilizado para entrenar y evaluar modelos de lenguaje en el análisis de sentimientos de reseñas en línea, y se justificó su elección en términos de calidad, relevancia y representatividad del lenguaje natural: Descripcion de hallazgos mencionado a la Tabla IV

En el análisis de sentimientos de reseñas en línea, se han utilizado diversos tipos de conjuntos de datos que cubren una amplia gama de dominios, estructuras lingüísticas y niveles de granularidad. Estos datasets han sido seleccionados por su calidad, relevancia y representatividad del lenguaje natural, lo que permite evaluar modelos de manera robusta y generalizable.

Por ejemplo, Yelp e IMDb se emplean como benchmarks clásicos para clasificar sentimientos en reseñas extensas de restaurantes y películas, respectivamente, ofreciendo diversidad temática y textos con longitudes considerables [9], [13]. Amazon Reviews se centra en productos, permitiendo probar la capacidad del modelo para captar matices de sentimiento y detectar comentarios falsos, incluso en entornos de datos

limitados [25]. Para tareas más específicas como el Análisis de Sentimientos Basado en Aspectos (ABSA), se utilizan conjuntos como SemEval-2014 y SentiHood, que incluyen etiquetas detalladas por aspecto y objetivo, favoreciendo una evaluación precisa del entendimiento contextual del modelo [15].

Adicionalmente, conjuntos como SST-1/SST-2 permiten analizar la capacidad del modelo para distinguir distintos grados de polaridad, mientras que Subj evalúa su habilidad para separar hechos de opiniones. En redes sociales, datasets como Sentiment140 y el de Twitter US Airline representan el lenguaje informal, abreviado y emocional de los usuarios [1], ideal para estudiar la generalización a lenguaje no estructurado.

También se incluyen conjuntos específicos por idioma, como LABR, HARD o ASTD para el árabe [2], y MSAC/ASAC para lenguas con pocos recursos, que permiten evaluar la adaptabilidad lingüística de los modelos. Finalmente, datasets como Go-Emotions y Jigsaw Toxic Comments se usan para tareas más complejas como la detección de emociones múltiples o comentarios tóxicos multilingües [23], [26], demostrando la necesidad de modelos capaces de manejar matices sutiles y ruido real.

En conjunto, estos datasets han sido cuidadosamente elegidos por su diversidad temática, estructural y lingüística, lo que garantiza que los modelos evaluados no solo sean precisos, sino también robustos, adaptables y representativos del lenguaje natural real en línea.

TABLE IV
CONJUNTOS DE DATOS Y SU JUSTIFICACIÓN DE USO

Conjunto de Datos	**Justificación / Uso**	**CITA**
Yelp (Full, Polarity, Service, Multimodal)	Evaluación de sentimientos en reseñas extensas y multimodales; incluye variantes geográficas.	[5], [11], [13]–[15]
SemEval (Restaurantes)	Clave para ABSA y TABSA; permite análisis de polaridades en aspectos específicos.	[3], [11]
Amazon Reviews (Amazon-P, Amazon-F)	Prueba la detección de matices y comentarios falsos; útil para tareas con recursos limitados.	[5], [22], [25]
SST-1 / SST-2	Benchmarks estándar para polaridad fina (SST-1) y binaria (SST-2) en reseñas de cine.	[7]
Twitter Airline / Sentiment140	Evalúan modelos en lenguaje informal y en tiempo real; incluye emojis y gran volumen.	[1], [8], [20]
SentiHood	ABSA dirigido; vincula aspectos (como seguridad) con ubicaciones específicas.	[**?**], [3]
LABR, HARD, ASTD (Árabe)	Prueban análisis de sentimientos en árabe; útiles para morfologías ricas y textos largos.	[2]
Go-Emotions	Permite clasificación de emociones más allá de polaridades básicas (27 emociones).	[26]
Jigsaw Toxic Comments	Multilingüe y desequilibrado; ideal para detección robusta de lenguaje tóxico.	[23]
MSAC / ASAC	Evalúan capacidad de generalización a idiomas con menos datos anotados.	[10]

3) Mecanismos de interpretabilidad y explicabilidad que han sido implementados en modelos de lenguaje para análisis de sentimientos, y como permiten entender la lógica detrás de las predicciones generadas: Descripcion de hallazgos mencionado a la Tabla V.

En el análisis de sentimientos, los modelos de lenguaje han incorporado mecanismos de atención como la auto-atención y la atención multi-cabeza, que permiten visualizar qué palabras influyen más en la predicción [15], facilitando la interpretación del razonamiento del modelo. En tareas más específicas como el análisis basado en aspectos (ABSA), se emplean variantes como la atención consciente del contexto o del aspecto (e.g., CG-BERT, SSEMGAT) [3], que revelan cómo se vinculan las palabras de opinión con aspectos específicos. Además, en escenarios multimodales, mecanismos como la atención al comportamiento del usuario permiten integrar datos adicionales, como información visual o de usuario, para enriquecer la explicación del modelo [18].

También se han implementado enfoques como los mecanismos de disentanglement y el análisis de importancia de características, que permiten separar atributos como sentimiento y estilo, o identificar qué tokens afectan más la salida del modelo [3], [26]. Técnicas como VMASK, lectura selectiva o análisis de gradientes ayudan a destacar o suprimir palabras clave, permitiendo evaluar el impacto directo de esas palabras en la predicción [16]. Estas estrategias no solo mejoran la

interpretabilidad, sino que también revelan errores potenciales del modelo, como malinterpretar ironías o ignorar señales contextuales relevantes.

Finalmente, se han desarrollado métodos jerárquicos y explicaciones generadas que estructuran la interpretación desde palabras individuales hasta temas globales del documento (como en HINT), y otros que utilizan marcadores del discurso o estadísticas del corpus para identificar señales lingüísticas explícitas. Además, modelos como PRAG pueden generar explicaciones en lenguaje natural basadas en preguntas y respuestas [21], mientras que técnicas como la cadena de pensamiento (Chain of Thought) permiten que modelos grandes como LLaMA-3 expongan su razonamiento paso a paso [22]. Estas explicaciones automáticas son complementadas por la evaluación humana, que valida su claridad, fidelidad y utilidad para usuarios finales.

TABLE V
MÉTODOS PARA INTERPRETABILIDAD Y SU FUNCIÓN

Método	**Cómo ayudan a entender**	**CITA**
Auto-atención y multi-cabeza	Revelan qué palabras influyen más en la predicción al observar pesos de atención. Diferentes cabezas se enfocan en distintas regiones.	[1], [6], [11], [15], [23]
Atención consciente del contexto/aspecto	Identifican cómo el modelo conecta aspectos (como ”precio”) con palabras de opinión relevantes dentro de una oración.	[3], [11]
Atención al comportamiento del usuario	Muestra cómo las preferencias del usuario afectan la atención hacia ciertas características de texto o visuales.	[18]
Separación de espacios latentes	Permite visualizar cómo se aíslan atributos como sentimiento o estilo, y cómo se preserva el contenido original (ej. usando t-SNE).	[26]
Análisis de sensibilidad (gradientes)	Identifica qué tokens afectan más la predicción del modelo.	[3]
VMASK (Máscaras variacionales)	Visualiza qué palabras son clave al comparar qué ocurre cuando se ocultan o se conservan.	[16]
Lectura selectiva	Resalta solo tokens relevantes (como ”wonderful”, ”bad”), mostrando enfoque eficiente en palabras con fuerte polaridad.	[2]
Máscara y generación	Muestra de forma transparente qué palabras fueron cambiadas durante transferencia de estilo y por qué.	[13]
Marcadores del discurso (DMs)	Usa pistas lingüísticas explícitas (como ‘luckily”, sadly”) para revelar inferencias semánticas del modelo.	[24]
Interpretaciones jerárquicas (HINT)	Muestra cómo el modelo entiende texto en niveles (palabra, oración, documento), incluyendo temas y polaridad.	[16]
Características estadísticas del corpus (AGN)	Muestra cómo el modelo combina estadísticas del corpus con atención para identificar palabras discriminativas.	[7]
Preguntas y respuestas explicativas (PRAG)	Genera explicaciones en lenguaje natural basadas en contenido real, facilitando comprensión directa por humanos.	[21]
Cadena de pensamiento (Chain of Thought - CoT)	Expone pasos lógicos internos del modelo (especialmente en LLMs), mostrando cómo llega a una conclusión.	[22]
Evaluación manual de explicaciones	Verifica si las explicaciones generadas son comprensibles, fieles al modelo y útiles para humanos. Evalúa precisión, fidelidad y relevancia.	[16]

4) Estrategias que han sido empleadas para mejorar la eficiencia computacional de los modelos de lenguaje aplicados al análisis de sentimientos sin comprometer significativamente su precisión: Descripcion de hallazgos mencionado a la Tabla VI

Para mejorar la eficiencia computacional en modelos de lenguaje para análisis de sentimientos, se han implementado diversas optimizaciones arquitectónicas, como el uso de GRUs en lugar de LSTMs, debido a su menor complejidad estructural

y capacidad para entrenar más rápido sin pérdida de precisión [23]. Además, se han desarrollado modelos híbridos, como combinaciones de BERT con BiGRU o BiLSTM [20], que mejoran la precisión aprovechando tanto el poder representacional de los Transformers como la eficiencia de las redes recurrentes. También se utilizan representaciones de oraciones compactas mediante mecanismos como attention bridge, y métodos de disentanglement eficientes que evitan técnicas computacionalmente costosas como las adversariales. La distilación de modelos (DistilBERT) permite reducir el tamaño de los modelos sin sacrificar desempeño [6].

En cuanto al entrenamiento, se han adoptado estrategias de transferencia y aprendizaje eficiente, como el fine-tuning de modelos preentrenados en lugar de entrenarlos desde cero, y métodos como LoRA para adaptar LLMs de manera liviana y rápida [22]. Se han explorado técnicas como el aprendizaje semi-supervisado con marcadores del discurso, el aprendizaje contrastivo para mejorar representaciones sin requerir arquitecturas complejas, y el aprendizaje multi-tarea para compartir información entre tareas relacionadas [19], [26]. Además, estrategias como la optimización con algoritmos genéticos o la reducción del espacio de búsqueda ayudan a acelerar la convergencia durante el entrenamiento.

Por otro lado, en el manejo de datos, se ha priorizado el uso de mecanismos de lectura eficiente, como KALLs o lectura selectiva, que reducen la cantidad de información a procesar manteniendo una alta precisión [9]. También se emplean máscaras variacionales (VMASK) para enfocarse en tokens clave, y se fusionan estadísticas del corpus con embeddings para mejorar la clasificación sin aumentar el costo computacional [16]. En contextos donde el tiempo es crítico, modelos como TriCNN-CatBoost se han diseñado para operar en tiempo real con bajos requerimientos de memoria y procesamiento [5], lo que demuestra que es posible mantener una alta precisión con un uso de recursos optimizado.

TABLE VI
ESTRATEGIAS DE OPTIMIZACIÓN Y SUS BENEFICIOS

Estrategia	**Descripción / Beneficio**	**CITA**
Uso de GRU sobre LSTM	Mayor eficiencia y velocidad con igual o mejor rendimiento usando menos datos.	[15], [23]
Modelos híbridos BERT + BiGRU/BiLSTM	Combina potencia semántica de BERT con eficiencia de GRU/LSTM, mejorando precisión y rendimiento.	[20]
Attention Bridge + Representación fija	Resume secuencias en vectores compactos, equilibrando eficiencia y precisión según la tarea.	[15]
Disentanglement eficiente (CLD)	Separa atributos (sentimiento/estilo) sin métodos adversariales, reduciendo el costo de entrenamiento.	[26]
Distilación de modelos (DistilBERT, TinyBERT)	Reduce tamaño y carga computacional manteniendo precisión aceptable.	[6], [24]
Fine-tuning de modelos preentrenados (BERT, RoBERTa, LLaMA-3)	Ahorra costos frente a entrenar desde cero; mejora rendimiento con menos datos.	[6], [8], [14], [22], [27]
LoRA + VGST para LLMs	Adaptación rápida y eficiente de LLaMA3; menor costo y alta velocidad con precisión competitiva.	[22]
Aprendizaje semi-supervisado con DMs	Genera datos débilmente etiquetados para escenarios zero/few-shot; útil en dominios con pocos datos.	[24]
Aprendizaje contrastivo supervisado (SuperContext)	Mejora la representación sin arquitecturas complejas ni bancos de memoria.	[10]
Aprendizaje multi-tarea (MTL)	Aprende múltiples tareas a la vez, mejorando generalización y reduciendo necesidad de grandes datasets.	[4]
Optimización basada en búsqueda (GA, reducción de espacio)	Acelera el entrenamiento evitando óptimos locales, útil para eficiencia global del sistema.	[9], [28]
Lectura Selectiva (e.g., KALLs, modelos árabes)	Clasificación eficiente leyendo solo tokens clave; reduce cómputo con precisión competitiva.	[2]
VMASK (máscaras variacionales)	Filtra palabras poco útiles, mejorando interpretabilidad y reduciendo carga computacional.	[16]
Fusión estadística adaptativa (AGN)	Combina información semántica con frecuencia de palabras sin aumentar el costo computacional.	[7]
Evitar preprocesamiento tradicional	En algunas tareas (e.g., detección tóxica), omitir pasos como eliminar stop words puede acelerar y mejorar resultados.	[6]
TriCNN-CatBoost	Procesamiento ultrarrápido de comentarios falsos (115 μs por muestra), bajo consumo de memoria, eficiente y preciso.	[5]

IV. Discusión

Aunque BERT ha sido fundamental en el análisis de sentimientos, diversos modelos híbridos han superado sus limitaciones en eficiencia y adaptabilidad. Liu et al. [29] combinan BERTopic con RoBERTa para mejorar la detección de tópicos y emociones, mientras que Mou y Wang [30] integran atención y redes BiGRU para lograr mayor precisión en reseñas de un dominio específico. Sabiri et al. [31] resaltan que los sistemas híbridos permiten personalización y versatilidad en distintos contextos. Asimismo, Nowrozy et al. [32] y Raza et al. [33] destacan el valor de modelos como GPT para tareas complejas y su impacto en sectores diversos. En el contexto de videojuegos, estas estrategias pueden considerarse para analizar las reseñas de jugadores disponibles en plataformas como Steam y Epic Games Store, sin asumir que los conjuntos de datos originales de cada estudio pertenecen a este dominio.

La selección de conjuntos de datos para entrenar modelos de análisis de sentimientos ha priorizado su representatividad y relevancia contextual. Liu et al. [29] emplearon datos de redes sociales chinas para capturar emociones reales sobre productos automotrices, mientras que Mou y Wang [30] usaron reseñas auténticas de Ctrip.com. Sabiri et al. [31] destacan que el volumen y la variedad de datos son fundamentales en sistemas híbridos, especialmente en dominios como e-commerce. Por su parte, Nowrozy et al. [32] validan su modelo en entornos sensibles como el médico, y Raza et al. [33] enfatizan la utilidad de corpus amplios y no estructurados en distintos sectores. Estas estrategias reflejan la importancia de usar datos ricos y específicos para lograr modelos robustos y generalizables.

Diversos enfoques han sido propuestos para dotar a los modelos de lenguaje de mayor interpretabilidad en el análisis de sentimientos. Por ejemplo, Mou y Wang [30] integran mecanismos de atención para resaltar tópicos clave y palabras con mayor carga emocional, facilitando así la comprensión del foco del modelo. En sistemas de recomendación de videojuegos, mecanismos equivalentes pueden utilizarse para identificar términos relacionados con jugabilidad, gráficos, historia, rendimiento u otros aspectos expresados por los jugadores. Xie et al., como mencionan Nowrozy et al. [32], aplican estructuras jerárquicas que generan explicaciones textuales, haciendo explícita la lógica detrás de las predicciones. Asimismo, Sabiri et al. [31] destacan que en sistemas híbridos, la explicabilidad es crítica para garantizar recomendaciones confiables, especialmente cuando se combinan múltiples fuentes de datos. Estos mecanismos permiten no solo justificar decisiones, sino también aumentar la confianza del usuario en sistemas de análisis automático.

Para mejorar la eficiencia computacional sin sacrificar precisión en el análisis de sentimientos, se han adoptado diversas estrategias centradas en arquitectura y tratamiento de datos. Mou y Wang [30] muestran que integrar mecanismos de atención selectiva reduce el procesamiento redundante en textos extensos. Esta estrategia resulta pertinente para escenarios de videojuegos, donde pueden existir grandes volúmenes de reseñas generadas por jugadores en plataformas digitales. Además, Liu et al. [29] utilizan modelos optimizados como RoBERTa en combinación con técnicas ligeras de agrupamiento, equilibrando precisión y rendimiento. Por su parte, Moukafih et al., citados en Sabiri et al. [31], proponen embeddings contrastivos eficientes como SuperConText, que eliminan la necesidad de estructuras complejas. Finalmente, Ein-Dor et al., discutidos por Nowrozy et al. [32], introducen datos débilmente etiquetados para disminuir la dependencia de corpus extensos. Estas aproximaciones permiten implementar modelos más livianos y escalables sin comprometer su efectividad.

V. Conclusiones

Los modelos híbridos y alternativos a BERT han demostrado mejoras significativas en la precisión, eficiencia y capacidad de interpretación en el análisis de sentimientos de reseñas en línea. Estos avances se logran al combinar la potencia representacional de los Transformers con arquitecturas eficientes como BiGRU o BiLSTM, o integrando características estadísticas y mecanismos de atención contextual/aspecto-guiada. Modelos como LLaMA3, SEML y SenDM superan a BERT en diversos conjuntos de datos al optimizar la transferencia de conocimiento y la eficiencia en tiempo real. Además, la integración multimodal y la personalización, como en UsbVisdaNet o PRAG, amplían las capacidades de análisis, reforzando la tendencia hacia modelos más ligeros, explicables y adaptables que superan las limitaciones de BERT.

La selección de conjuntos de datos para entrenar y evaluar modelos de lenguaje en el análisis de sentimientos se ha basado en su diversidad temática, estructural y lingüística, garantizando robustez y generalización. Se han utilizado benchmarks clásicos como Yelp e IMDb para reseñas extensas, Amazon Reviews para matices y detección de comentarios falsos, y SemEval o SentiHood para análisis basado en aspectos. La inclusión de datos de redes sociales como Sentiment140 y Twitter US Airline permite evaluar el manejo de lenguaje informal, mientras que conjuntos multilingües como LABR, HARD, ASTD, MSAC y ASAC prueban la adaptabilidad lingüística de los modelos. Esta cuidadosa elección de datos refleja la importancia de corpus ricos y específicos para desarrollar modelos precisos y representativos del lenguaje natural en entornos reales.

Los modelos de lenguaje han incorporado mecanismos robustos de interpretabilidad y explicabilidad para desvelar la lógica detrás de sus predicciones en el análisis de sentimientos. Las técnicas de auto-atención y atención multi-cabeza permiten visualizar las palabras que más influyen en la salida del modelo, mientras que la atención consciente del contexto o del aspecto (e.g., CG-BERT, SSEMGAT) revela la conexión entre opiniones y aspectos específicos. Métodos como el análisis de sensibilidad, VMASK y la lectura selectiva resaltan el impacto directo de tokens clave, y las explicaciones generadas en lenguaje natural (PRAG, Chain of Thought) ofrecen un razonamiento paso a paso, aumentando la confianza del usuario y facilitando la depuración del modelo.

Para optimizar la eficiencia computacional sin sacrificar precisión, se han implementado diversas estrategias arquitectónicas, de entrenamiento y de manejo de datos. Las optimizaciones arquitectónicas incluyen el uso de GRUs sobre LSTMs para mayor velocidad y menor complejidad, modelos híbridos que combinan BERT con redes recurrentes eficientes, y la destilación de modelos como DistilBERT para reducir el tamaño. En el entrenamiento, se prioriza el fine-tuning de modelos preentrenados y técnicas como LoRA para adaptación liviana. Además, el manejo de datos se beneficia de la lectura selectiva (KALLs, VMASK) para reducir la información a procesar, y modelos como TriCNN-CatBoost demuestran capacidad de operación en tiempo real con bajos requisitos de memoria. Estas aproximaciones permiten la implementación de modelos más ligeros y escalables manteniendo una alta efectividad. En el ámbito de los videojuegos, su aplicación puede orientarse al análisis de reseñas de jugadores procedentes de plataformas como Steam y Epic Games Store, con el propósito de aportar información útil a sistemas de recomendación personalizados.

A Dios, por ser la fuente de sabiduría, fortaleza y esperanza durante todo este proceso académico y personal. A nuestra familia, por su amor incondicional, su apoyo constante y por creer siempre en mí, incluso en los momentos más difíciles. A nuestro docente guía, por su orientación, compromiso y paciencia a lo largo de esta investigación, cuya guía fue fundamental para el desarrollo de este trabajo. Y a la universidad, por fomentar la investigación como herramienta de transformación académica y social, y por brindarnos el espacio y los recursos necesarios para crecer como profesional y como persona.

REFERENCES

[1] K. L. Tan, C. P. Lee, K. M. Lim, and K. S. Muthu Anbananthen, "Sentiment analysis with ensemble hybrid deep learning model," *IEEE Access*, vol. 10, 2022.

[2] A. no especificados en la fuente, "Selective reading for arabic sentiment analysis," *Desconocido*, 2021, información completa del autor y la publicación no disponible en la fuente.

[3] ——, "Context-guided BERT for targeted aspect-based sentiment analysis," in *Proceedings of the Thirty-Fifth AAAI Conference on Artificial Intelligence*, 2021, información completa del autor y las páginas no disponible en la fuente.

[4] N.-Q. Wang, "Research on deep learning-based social media word-of-mouth analysis model," *IEEE Access*, vol. 12, 2024.

[5] J. Peng, "Identification of fake comments in e-commerce based on triple convolutional twin network and CatBoost model," *IEEE Access*, vol. 12, pp. ????–????, 2024.

[6] V. Maslej-Krešňáková, M. Sarnovský, P. Butka, and K. Machová, "Comparison of deep learning models and various text pre-processing techniques for the toxic comments classification," *Applied Sciences*, vol. 10, no. 8631, 2020.

[7] A. no especificados en la fuente, "Merging statistical feature via adaptive gate for improved text classification," in *Proceedings of the Thirty-Fifth AAAI Conference on Artificial Intelligence*, 2021, información completa del autor y las páginas no disponible en la fuente.

[8] ——, "Designing a novel technique for evaluation of tourism informatization in scenic areas," *Journal of King Saud University-Computer and Information Sciences*, 2022, información completa del autor y las páginas no disponible en la fuente.

[9] T. Huang, G. Shen, and Z. Deng, "Leap-lstm: Enhancing long short-term memory for text categorization," in *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence, IJCAI 2019*, Macao, China, 2019, pp. 5017–5023.

[10] Y. Moukafih, N. Sbihi, M. Ghogho, and K. Smaili, "SuperConText: Supervised contrastive learning framework for textual representations," *IEEE Access*, vol. 11, pp. ????–????, 2023.

[11] X. Xin, A. Wumaier, Z. Kadeer, and J. He, "SSEMGAT: Syntactic and semantic enhanced multi-layer graph attention network for aspect-level sentiment analysis," *Applied Sciences*, vol. 13, no. 5085, 2023.

[12] T. Hosking, H. Tang, and M. Lapata, "Hierarchical indexing for retrieval-augmented opinion summarization (HIRO)," *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 1533–1555, 2024.

[13] C. Wu, X. Chen, and X. Li, "Mask transformer: Unpaired text style transfer based on masked language," *Applied Sciences*, vol. 10, no. 6196, pp. ???–???, 2020, dOI inferido del patrón de Applied Sciences de MDPI.

[14] A. Areshey and H. Mathkour, "Transfer learning for sentiment classification using bidirectional encoder representations from transformers (BERT) model," *Sensors*, vol. 23, no. 5232, 2023.

[15] R. Vázquez, A. Raganato, M. Creutz, and J. Tiedemann, "A systematic study of inner-attention-based sentence representations in multilingual neural machine translation," *Computational Linguistics*, vol. 46, no. 2, p. 387, 2020. [Online]. Available: http://direct.mit.edu/coli/article-pdf/46/2/387/1847640/coli$_{a}$0377.*pdf*

[16] A. no especificados en la fuente, "Hierarchical interpretation of neural text classification," *Transactions of the Association for Computational Linguistics*, vol. 48, pp. 987–???, 2022, información completa del autor no disponible en la fuente.

[17] B. Kitchenham and P. Brereton, "A systematic review of systematic review process research in software engineering," *Information and Software Technology*, vol. 55, no. 12, pp. 2049–2075, 2013. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0950584913001560

[18] S. Hou, G. Tuerhong, and M. Wushouer, "UsbVisdaNet: User behavior visual distillation and attention network for multimodal sentiment classification," *Sensors*, vol. 23, no. 4829, 2023.

[19] N. Li, C.-Y. Chow, and J.-D. Zhang, "SEML: A semi-supervised multi-task learning framework for aspect-based sentiment analysis," *IEEE Access*, vol. 8, pp. 189 287–189 297, 2020.

[20] A. Talaat, "Sentiment analysis classification system using hybrid BERT models," *Journal of Big Data*, vol. 10, no. 1, p. 110, 2023, dOI no especificado en la fuente.

[21] A. no especificados en la fuente, "Factual and informative review generation for explainable recommendation," in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2023, información completa del autor y las páginas no disponible en la fuente.

[22] ——, "Sentiment analysis of product reviews using fine-tuned LLaMa-3 model," in *ITM Web of Conferences*, vol. 70, 2025, p. 04021, conferencia DAI 2024. Información completa del autor no disponible en la fuente.

[23] G. Song, D. Huang, and Z. Xiao, "A study of multilingual toxic text detection approaches under imbalanced sample distribution," *Information*, vol. 12, no. 205, 2021.

[24] A. no especificados en la fuente, "Fortunately, discourse markers can enhance language models," in *The Thirty-Sixth AAAI Conference on Artificial Intelligence (a-22)*, 2022.

[25] S. Pradeepa, E. Jomy, S. Vimal, M. M. Hassan, G. Dhiman, A. Karim, and D. Kang, "HGATT_LR: transforming review text classification with hypergraphs attention layer and logistic regression," *Desconocido*, 2024, información de la revista y las páginas no disponible en la fuente.

[26] A. no especificados en la fuente, "Text attribute control via closed-loop disentanglement," *Desconocido*, 2022, información completa del autor y la publicación no disponible en la fuente.

[27] ——, "Transformer based contextual model for sentiment analysis of customer reviews," *International Journal of Advanced Computer Science and Applications*, vol. 12, no. 11, 2021, información completa del autor y las páginas no disponible en la fuente.

[28] ——, "Generating natural language attacks in a hard label setting," in *Proceedings of the Thirty-Fifth AAAI Conference on Artificial Intelligence*, 2021, información completa del autor y las páginas no disponible en la fuente.

[29] Y. Liu, D. Zhang, Q. Wan, and Z. Lin, "Innovative mining of user requirements through combined topic modeling and sentiment analysis: An automotive case study," *Sensors*, vol. 25, no. 6, p. 1731, 2025.

[30] T. Mou and H. Wang, "Online comments of tourist attractions combining artificial intelligence text mining model and attention mechanism," *Scientific Reports*, 2025.

[31] B. Sabiri, A. Khtira, B. El Asri, and M. Rhanoui, "Hybrid quality-based recommender systems: A systematic literature review," *J. Imaging*, vol. 11, no. 1, p. 12, 2025.

[32] R. Nowrozy, K. Ahmed, and H. Wang, “Gpt, ontology, and caabac: A tripartite personalized access control model anchored by compliance, context and attribute,” *PLoS ONE*, vol. 20, no. 1, p. e0310553, 2025.
[33] M. Raza, Z. Jahangir, M. B. Riaz, M. J. Saeed, and M. A. Sattar, “Industrial applications of large language models,” 2025.